2020년 - C형 인쇄용(50문제)

총점 48/50

✓ 1. 빅데이터가 만들어 내는 본질적인 변화에 대한 설명 중 적절하지 않은 것은? *1/1

- 사전처리에서 사후 처리시대로의 변화
- 표본조사에서 전수조사로의 변화
- 질보다 양을 강조하는 변화
- 상관관계에서 인과관계로의 변화 ✓

의견 보내기

1-13. 빅데이터의 가치 산정, 본질적 변화
사전처리 -> 사후처리
표본조사 -> 전수조사
질(Quality) -> 양(Quantity)
인과관계 -> 상관관계

✓ 2.기업의 성과분석 현황에 대한 설명 중 적절하지 못한 것은? * 1/1

- 성과가 높은 기업과 성과가 낮은 기업이 큰 차이를 보이는 부분은 분석에 대한 태도와 분석의 응용 부분이다.
- 성과가 높은 기업들이 가치 분석적 통찰력을 갖췄다고 대답한 비율이 낮다.
- 성과가 높은 기업도 분석 역량을 활용하지 못하고 있다. ✓
- 성과가 낮은 기업들은 일상 업무에 데이터 분석을 활용하지 못하고 있다.

의견 보내기

성과가 높은 기업들은 분석 역량을 활용하고 있다.
https://colab.research.google.com/drive/1cCk43pbnapr0mxOSiC8ssN3ya5TJwSqG#scrollTo=h78ybrWhgw1k 여기를 참조하세요!

✓ 3. 다음 중 데이터 사이언티스트의 필요 역량으로 가장 부적절한 것은 무엇인가? *1/1

- ○ 통찰력 있는 분석
- ○ 설득력 있는 전달
- ○ 다 분야간 협력
- ◉ 네트워크 최적화 ✓

의견 보내기

1-23. 데이터 사이언티스트의 역량
소프트 스킬 : 통찰력 있는 분석, 설득력 있는 전달, 다분야 간 협력
하드 스킬 : 빅데이터에 대한 이론적 지식, 분석 기술에 대한 숙련

✓ 4. 다음 데이터의 특징 중 가장 올바르지 않은 것은? * 1/1

- ○ 암묵지는 시행착오와 오랜 경험을 통해 개인에게 습득된 무형의 지식이다.
- ○ 데이터는 존재론적 특징과 함께 당위적 특징의 성격을 가지고 있다.
- ○ 데이터는 개별 데이터 자체로는 의미가 중요하지 않은 객관적인 사실을 의미한다.
- ◉ 데이터의 유형은 암묵지와 형식지로 구분한다. ✓

의견 보내기

1-01 데이터의 유형, 1-02 암묵지, 형식지
암묵지와 형식지 : 가장 널리 알려진 지식의 차원
데이터 유형은 정량적, 정성적 데이터로 구분됨

✓ 5. 데이터에 관한 구조된 데이터로 다른 데이터를 설명해 주는 데이터를 무엇이라 하는가? *1/1

- (●) 메타데이터 ✓
- ( ) 데이터 사전
- ( ) 데이터웨어하우스
- ( ) 데이터베이스

의견 보내기

데이터 사전: 일반 사전처럼 데이터베이스에 저장되어 있는 데이터를 정확하고 효율적으로 이용하기 위해 참고해야 되는 스키마, 사상 정보, 다양한 제약조건 등을 저장
데이터웨어하우스: 사용자의 의사 결정에 도움을 주기 위하여, 다양한 운영 시스템에서 추출, 변환, 통합되고 요약된 데이터베이스

✓ 6. 다음은 빅데이터 활용 기술에 관한 설명이다. 적절하지 않은 것은? * 1/1

- (●) 택배 차량을 어떻게 배치하는 것이 비용에 효율적인가? : 유형분석 ✓
- ( ) 응급실에서 의사를 어떻게 배치하는 것이 가장 효율적인가? : 유전알고리즘
- ( ) 맥주 구매자가 기저귀를 더 많이 구매하는가? : 연관분석
- ( ) 사용자의 만족도가 충성도에 어떤 영향을 미치는가? : 회귀분석

의견 보내기

1-15. 빅데이터 활용 기법
택배 차량 배치는 최적화에 문제에 대한 것으로 "유전 알고리즘 " 에 관한 것이다

✓ 7. 다음 중 딥러닝(Deep Learning)과 관련된 분석기법은? * 1/1

- (●) ANN ✓
- ( ) 로지스틱 회귀분석
- ( ) 연관분석
- ( ) 주성분분석

의견 보내기

딥러닝 관련 분석 기법 : ANN, DNN, CNN, RNN, LSTM, Autoencoder

✓ 8. 아래는 용어와 의미를 서로 연결한 것이다. 다음 중 용어-의미가 잘못 연결된 것을 모두 나열한 것은? * 1/1

- OLTP - 다차원의 데이터를 대화식으로 분석하기 위한 소프트웨어
- BI(business Intelligence) - 경영 의사결정을 위한 통계적이고 수학적인 분석에 초점을 둔 기법
- BA(Business Analytics) - 데이터 기반 의사결정을 지원하기 위한 리포트 중심의 도구
- Data Mining - 대용량 데이터로부터 의미 있는 관계, 규칙, 패턴을 찾는 과정

- ( ) OLTP
- ( ) OLTP, BI
- (●) OLTP, BI, BA ✓
- ( ) OLTP, BI, BA, Data Mining

의견 보내기

1-09. 기업 내부 데이터베이스 솔루션
다차원의 데이터를 대화식으로 분석하기 위한 소프트웨어 -> OLAP
BI, BA의 설명은 바뀌어 있음

✓ 9. 빅데이터가 만들어 내는 본질적인 변화에 대한 설명이다. 1, 2에 적절한 단어는 무엇인가? 1. XXXX, 2. XXXX 로 대답해 주세요. *1/1

(1) 은 어떤 현상에 대하여 현상을 발생시킨 원인과 그 결과 사이의 관계를 말하고,
(2) 는 어떤 두 현상이 관계가 있음을 말하지만 어느 쪽이 원인인지 알 수 없다.

1. 인과관계, 2.상관관계 ✓

✓ 10. 빅데이터 비즈니스 측면에서 “공동 활용의 목적으로 구축된 유무형의 구조물”을 의미하는 빅데이터 기능을 무엇이라 하는가? *1/1

플랫폼 ✓

의견 보내기

1-12. 빅데이터의 역할
석탄/철, 원유, 렌즈, 플랫폼
플랫폼 : 비즈니스 측면에서는 '공동 활용의 목적으로 구축된 유/무형의 구조물 ' 을 의미함, 페이스북, API 공개

✓ 1. 메타 데이터와 데이터 사전의 관리 원칙을 수립하고, 빅데이터의 경우 데이터 생명주기 관리방안 수립에 해당되는 데이터 거버넌스 체계를 무엇이라 하는가? *1/1

- ○ 데이터 표준화
- ◉ 데이터 관리체계 ✓
- ○ 데이터 저장소 관리
- ○ 표준화 활동

의견 보내기

2-28. 데이터 거버넌스 체계 수립
데이터 표준화 단계 : 데이터 표준용어 설정, 명명규칙 수립, 메타 데이터 구축, 데이터 사전 구축
데이터 관리체계 : 메타데이터와 데이터 사전(Data Dictionary)의 관리 원칙 수립
데이터 저장소관리 : 메타데이터 및 표준 데이터를 관리하기 위한 전사 차원의 저장소를 구성
표준화 활동 : 데이터 거버넌스 체계 구축 후, 표준 준수 여부를 주기적으로 점검, 모니터링

✓ 2. 마스터플랜 수립 시 적용 범위 및 방식의 고려요소가 아닌 것은? * 1/1

- ○ 업무 내재화 적용 수준
- ○ 분석 데이터 적용 수준
- ◉ 투자 비용 수준 ✓
- ○ 기술 적용 수준

의견 보내기

2-18. 분석 마스터플랜 수립
분석 마스터플랜 수립 시 우선순위 고려요소
- 전략적 중요도, ROI(투자자본수익률), 실행 용이성
적용 범위/방식 고려요소
- 업무 내재화 적용 수준, 분석 데이터 적용 수준, 기술 적용 수준

(각종 '적용 수준'을 고려하네요!!)

✓ 3. CRISP-DM 분석절차에서 “위대한 실패”가 발생하는 구간은? * 1/1

- ◉ Evaluation – Business Understanding ✓
- ○ Modeling – Data Preparation
- ○ Data Preparation – Data Understanding
- ○ Evaluation - Deployment

의견 보내기

평가 결과에 따라 데이터 이해, 데이터 준비 단계를 반복할 수 있음

✓ 4. 다음 중 포트폴리오 사분면 분석에 대한 설명 중 적절하지 않은 것은? * 1/1

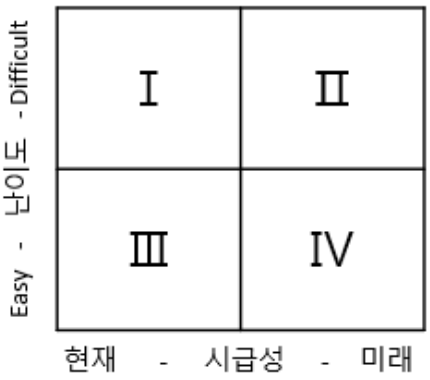

- (●) 사분면 분석에서 가장 우선적인 분석 과제 적용이 필요한 영역은 Ⅰ사분면이다. ✓
- ( ) 분석 과제를 바로 적용하기 어려워 우선순위가 낮은 영역은 Ⅱ 사분면이다.
- ( ) 시급성에 기준을 둔다면, Ⅲ → Ⅳ → Ⅱ 사분면 순이다.
- ( ) 난이도에 기준을 둔다면, Ⅲ → Ⅰ → Ⅱ 사분면 순이다.

의견 보내기

2-20. 분석 과제 우선순위 선정 기법
가장 우선적인 분석 과제 적용이 필요한 영역은 Ⅲ 사분면이다.

✓ 5. 다음 중 데이터 거버넌스에 대한 설명 중 적절하지 않은 것은? * 1/1

- ( ) 데이터 거버넌스의 구성요소는 원칙, 조직, 프로세스 이다.
- ( ) 기업은 데이터 거버넌스 체계를 구축함으로써 데이터의 가용성, 유용성, 통합성, 보안성, 안정성 등을 확보할 수 있다.
- ( ) 데이터 거버넌스란 모든 데이터에 대하여 정책 및 지침, 표준화, 운영조직 및 책임 등의 표준화된 관리체계를 수립하고 운영하는 프레임워크 및 저장소 구축을 의미한다.
- (●) 데이터 거버넌스는 독자적으로 수행해야만 하고 전사 차원의 IT 거버넌스나 EA의 구성요소로 구축되는 경우는 없다. ✓

의견 보내기

2-28. 데이터 거버넌스 체계 수립
데이터 거버넌스는 독자적으로 수행될 수도 있지만, 전사 차원의 IT 거버넌스나 EA(Enterprise Architecture)의 구성요소로써 구축되는 경우도 있음

✓ 6. CRISP – DM 분석방법론의 데이터 준비 단계의 Task가 아닌 것은? * 1/1

- ○ 데이터 정제
- ○ 데이터 통합
- ◉ 데이터 탐색 ✓
- ○ 분석용 데이터셋 선택

의견 보내기

2-09. CRISP-DM 분석 방법론
데이터 이해 : 초기 데이터 수집, 데이터 기술 분석, 데이터 탐색, 데이터 품질 확인
데이터 준비 : 분석용 데이터셋 선택, 데이터 정제, 데이터 통합, 데이터 포맷팅

✓ 7. 분석 과제 발굴의 접근방식에 대한 설명 중 적절하지 않은 것은? * 1/1

- ◉ 문제가 무엇인지(what)를 알고 답을 구하는 방식을 상향식 접근방식이라 한다. ✓
- ○ 디자인 씽킹 프로세스는 상향식 접근방식의 발산과 하향식 접근방식의 수렴단계를 반복적으로 수행하게 된다.
- ○ 분석과제발굴의 상향식과 하향식 접근방법은 실제 분석과정에서 혼용되어 활용되는 경우가 많다
- ○ 데이터를 활용하여 생각하지 못했던 인사이트를 도출하고 시행착오를 통해서 개선해가는 상향식 접근방식의 유용성이 점차 증가하고 있는 추세이다.

의견 보내기

2-11. 분석 과제 도출 방법
상향식 접근 방식은 문제의 정의 자체가 어려운 경우 사용함
문제가 주어지고 해법을 찾기 위해 사용하는 것은 '하향식 접근 방법'임

✓ 8. 분석 기획 고려 사항 중 장애 요소에 대한 부적절한 설명은? *

1/1

- 데이터 유형에 따라서 적용 가능한 솔루션 및 분석 방법이 다르기 때문에 유형에 대한 분석이 선행적으로 이루어져야 한다.
- 유사 분석 시나리오 및 솔루션이 있다면 이를 최대한 활용하는 것이 중요하다.
- 장애요소들에 대한 사전 계획 수립이 필요하다.
- (●) 이해하기 쉬운 모델보다는 복잡하고 정교한 모형이 더 효과적이다. ✓

의견 보내기

2-04. 분석 기획 시 고려 사항
가용한 데이터 : 데이터의 유형 분석이 선행적으로 이루어져야 함
적절한 유즈케이스 탐색 : 유사분석 시나리오 솔루션이 있다면 이것을 최대한 활용
장애요소들에 대한 사전 계획 수립 필요
분석 과제가 기업에 내재화 될 수 있도록 지속적인 교육 관리가 필요함

✓ 9. 빈 칸에 알맞은 용어는? *

1/1

식별된 비즈니스 문제를 데이터의 문제로 변환하여 정의하는 단계이다. 앞서 수행한 문제탐색의 단계가 무엇을 어떤 목적으로 수행해야 하는지에 대한 관점이었다면 ( ) 단계에서는 이를 달성하기 위해 필요한 데이터 및 기법을 정의하기 위한 데이터 분석의 문제로의 변환을 수행하게 된다.

문제정의 ✓

의견 보내기

2-12. 하향식 접근 방식
문제 탐색 – 문제 정의 – 해결 방안 탐색 – 타당성 검토

✓ 10. 아래 내용은 데이터 분석 단계의 어떤 Task에 대한 설명인가? * 1/1

분석용 데이터를 이용한 가설 설정을 통하여 통계모델을 만들거나 기계학습을 이용한 데이터의 분류, 예측, 군집 등의 기능을 수행하는 과정을 의미한다.

모델링 ✓

의견 보내기

2-10. 빅데이터 분석 방법론
분석기획 - 데이터 준비 - 데이터 분석 - 시스템 구현 - 평가 및 전개

2-10-3. 데이터 분석 단계
분석용 데이터 준비 - 텍스트 분석 - 탐색적 분석 - 모델링 - 모델 평가 및 검증

✓ 1. 아래의 불순도 측정 결과를 사용해서 구한 지니 지수는 얼마인가? * 1/1

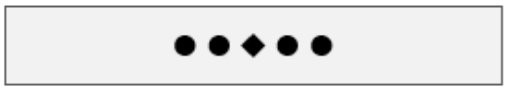

- 0.5
- 0.32 ✓
- 0.48
- 0.38

의견 보내기

3-82. 의사결정나무 모형

지니지수 식 : 1 - ∑(각 범주별수/전체수)2
= 1 − ((1/5)^2 + (4/5)^ 2) = 1 − (1/25+16/25)=8/25=0.32

✓ 2. 어떤 슈퍼마켓에서 고객 5명의 장바구니 구입품목이 다음과 같다고 한다. 연관규칙 딸기→사과에 대한 지지도는? *1/1

구입품목	거래건수
딸기, 배	100
사과	200
딸기, 사과	150
수박, 배, 사과	250
메론, 딸기, 사과	300

- (●) 45% ✓
- ( ) 65%
- ( ) 15%
- ( ) 25%

의견 보내기

3-99. 연관규칙 측정지표
지지도 = P(A∩B) : A와 B가 동시에 포함된 거래 수 / 전체 거래 수 = 450 / 1000 = 45%

✓ 3. 다음 확률분포에서 확률변수 x의 기댓값은? * 1/1

x	1	2	3
f(x)	1/6	1/2	1/3

- (●) 13/6 ✓
- ( ) 4/6
- ( ) 2
- ( ) 1

의견 보내기

3-53. 기댓값
이산형 확률변수 x의 기댓값 : $\sum x \cdot f(x)$
$= 1*1/6 + 2*3/6 + 3*2/6 = (1+6+6)/6 = 13/6$

✓ 4. 다음 중 아래 오분류표를 이용하여 F1값 구하면? * 1/1

오분류표		예측치	
		TRUE	FALSE
실제값	TRUE	40	60
	FALSE	60	40

- (●) 0.4 ✓
- ( ) 0.6
- ( ) 0.8
- ( ) 1.0

의견 보내기

3-91. 오분류표를 활용한 평가 지표
*F1 = 2 * (Precision * Recall) / (Precision + Recall)*
Precision = TP / (TP + FP) = 40 / 100 = 0.4
Recall = TP / (TP + FN) = 40 / 100 = 0.4
*= 2 * (0.4 * 0.4) / (0.4 + 0.4) = 0.32 / 0.8 = 0.4*

✓ 5. Hitters dataset의 일부이다. 다음 설명 중 적절하지 않은 것은? * 1/1

```
> summary(Hitters)
     AtBat            Hits         HmRun      NewLeague     Salary       
 Min.   : 16.0   Min.   :  1   Min.   : 0.00   A:176     Min.   :  67.5  
 1st Qu.:255.2   1st Qu.: 64   1st Qu.: 4.00   N:146     1st Qu.: 190.0  
 Median :379.5   Median : 96   Median : 8.00             Median : 425.0  
 Mean   :380.9   Mean   :101   Mean   :10.77             Mean   : 535.9  
 3rd Qu.:512.0   3rd Qu.:137   3rd Qu.:16.00             3rd Qu.: 750.0  
 Max.   :687.0   Max.   :238   Max.   :40.00             Max.   :2460.0  
                                                         NA's   :59
```

- (●) Salary 변수 분포는 왼쪽꼬리가 긴 분포를 가진다. ✓
- ( ) NewLeague 변수는 범주형 자료이다.
- ( ) Hits 변수에는 결측값이 없음을 알 수 있다.
- ( ) HmRun 변수의 최대값은 40이다.

의견 보내기

Salary의 경우 Median < Mean 이므로 오른쪽으로 꼬리가 긴 분포이다.

✓ 6. Default dataset에 대한 설명 중 적절하지 않은 것은? * 1/1

```
> summary(Default)
 default    student       balance           income
 No :9667   No :7056   Min.   :   0.0   Min.   :  772
 Yes: 333   Yes:2944   1st Qu.: 481.7   1st Qu.:21340
                       Median : 823.6   Median :34553
                       Mean   : 835.4   Mean   :33517
                       3rd Qu.:1166.3   3rd Qu.:43808
                       Max.   :2654.3   Max.   :73554
```

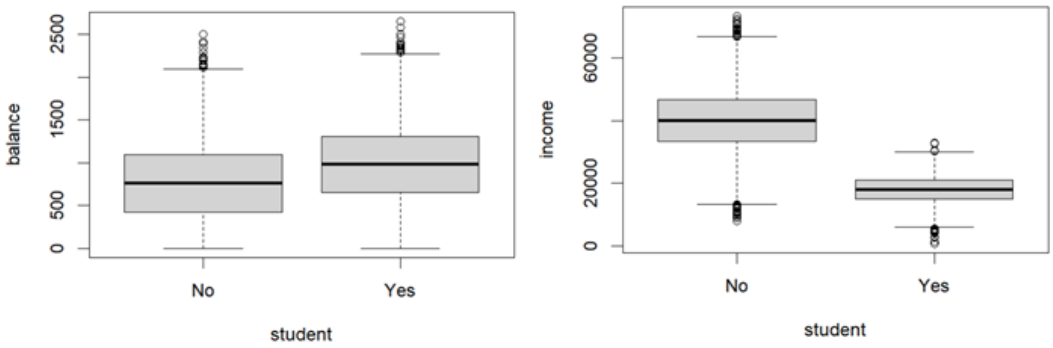

- (●) 학생인 경우가 학생이 아닌 경우보다 balance가 낮은 경향을 보인다. ✓
- ( ) 학생인 경우 income이 학생이 아닌 경우 보다 편차가 작다
- ( ) default와 student 변수는 범주형 데이터이다
- ( ) balance, income에 이상치가 있음을 알 수 있다

의견 보내기

3-26. 그래프 종류 – Boxplot
학생인 경우의 balance가 더 높은 경향을 보인다.

✓ 7. 군집 간의 거리에 기반하는 다른 연결법과는 달리 군집 내의 오차 제곱합(error sum square)에 기초하여 군집을 수행하는 계층적 군집분석의 거리측정을 무엇이라 하는가? *1/1

- ○ 중심연결법
- ○ 평균연결법
- ◉ 와드연결법 ✓
- ○ 최단연결법

의견 보내기

3-94. 계층적 군집(Hierarchical Clustering) (페이지 558)

와드연결법 : 계층적 군집내의 오차제곱합에 기초하여 군집을 수행하는 군집 방법
크기가 비슷한 군집끼리 병합하는 경향이 있음

✓ 8. 이산형 확률변수 x 의 기댓값은? * 1/1

- ◉ $E(x)=\sum xf(x)$ ✓
- ○ $E(x)=\int xf(x)$
- ○ $E(x)=E[(x-\mu)^2]$
- ○ $E(x)=x^3-x^2)$

의견 보내기

3-53. 기댓값
이산형 확률변수 x의 기댓값 : $E(X) = \sum x \cdot f(x)$
연속형 확률변수 x의 기댓값 : $E(X) = \int x \cdot f(x)$

✓ 9. 다음 2개의 좌표에 대한 맨해튼 거리를 구하면? * 1/1

a(100, 5), b(50, 7)

- (●) 52 ✓
- ( ) 43
- ( ) 138
- ( ) 95

의견 보내기

3-94. 계층적 군집의 거리
맨해튼 거리는 절대값의 합으로 구한다
|100-50|+|5-7|=52

✓ 10. 다음 중 순위만 제공할 뿐 양적인 비교는 불가능한 척도는 무엇인가? * 1/1

- ( ) 명목척도
- (●) 순서척도 ✓
- ( ) 구간척도
- ( ) 비율척도

의견 보내기

3-41. 척도의 종류
명목척도 : 단순히 측정 대상의 특성을 분류하거나 확인하기 위한 목적 (성별, 혈액형)
서열(순위, 순서)척도 : 순위만 제공할 뿐 양적인 비교는 할 수 없음 (메달, 선호도, 만족도)
등간척도(구간척도) : 순위를 부여하되 순위 사이의 간격이 동일하여 양적인 비교가 가능, 절대 0점 존재하지 않음 (온도계 수치, 물가지수)
비율척도(Ratio scale) 절대 0점이 존재하여 측정값 사이의 비율 계산이 가능한 척도

✓ 11. 다음 두 개의 확률변수 X, Y의 공분산에 대한 설명 중 옳지 않은 것은? * 1/1

- ○ 공분산이 양수이면 X가 증가할 때 Y도 증가한다.
- ○ 공분산이 음수이면 X가 증가할 때 Y는 감소한다.
- ○ 공분산이 0이면 두 변수간에는 아무런 선형관계가 없으며 두 변수는 서로 독립적인 관계이다.
- ◉ -1 ≦ Cov(X, Y) ≦ 1, 공분산의 크기는 -1~1 사이의 범위를 갖는다. ✓

의견 보내기

3-72. 상관 분석
공분산(Covariance)
2개의 확률변수의 선형 관계를 나타내는 값
하나의 변수가 상승하는 경향을 보일 때 다른 값도 상승하는 선형 상관성이 있다면 양의 공분산을 갖음
공분산이 0이면 서로 독립이며, 관측값들이 4면에 균일하게 분포되어 있다고 추정할 수 있음

✓ 12. 다음 잔차도는 회귀분석의 어떤 가정을 위배하고 있는가? * 1/1

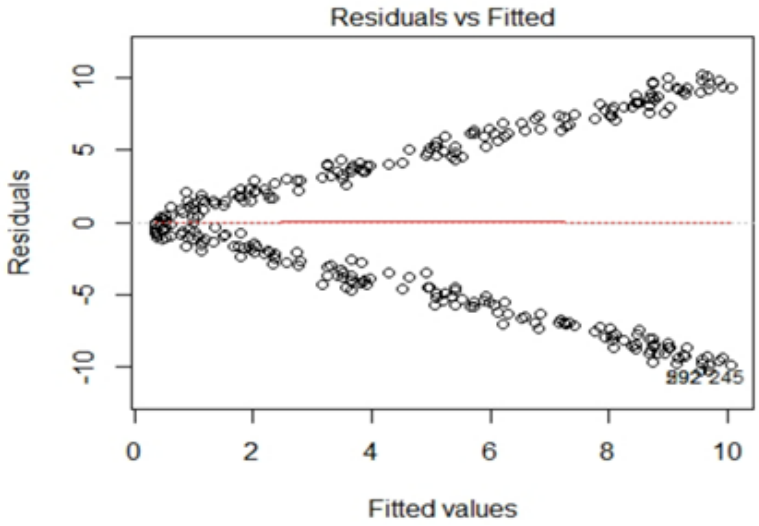

- ○ 선형성
- ○ 비상관성
- ◉ 등분산성 ✓
- ○ 독립성

의견 보내기

3-64. 회귀 모형의 가정
선형성 : 독립변수의 변화에 따라 종속변수도 변화하는 선형(linear) 모형이다
독립성 : 잔차와 독립변수의 값이 관련되어 있지 않다
정규성 : 잔차항이 정규분포를 이뤄야 한다
등분산성 : 잔차항들의 분포는 동일한 분산을 갖는다
비상관성 : 잔차들끼리 상관이 없어야 한다 (Durbin-Watson 통계량 확인)

✓ 13. 다음 중 중심극한정리에 대한 설명 중 적절하지 않은 것은? * 1/1

- (●) 모집단의 분포가 정규분포에 가까워져야 표본평균의 분포가 정규분포로 근사하게 된다 ✓
- ( ) 중심극한정리가 성립하기 위해서는 표본크기가 최소 30 이상이어야 한다.
- ( ) 모집단의 분포와 상관없이 표본의 크기가 커짐에 따라 정규분포에 가까워지게 된다.
- ( ) 표본크기가 N인 확률표본의 표본평균은 N이 충분히 크면 근사적으로 정규분포를 따르게 된다

의견 보내기

3-54. 연속형 확률분포
중심극한정리 : 모집단의 분포와 상관 없이 N이 충분히 크면 표본 평균의 분포가 정규분포로 근사하게 된다

✓ 14. 다음 중 이상값 검색을 활용한 응용시스템으로 가장 적절한 것은? * 1/1

- ( ) 장바구니 분석시스템
- ( ) 교차 판매 시스템
- (●) 부정사용방지 시스템 ✓
- ( ) 추천 시스템

의견 보내기

이상치 검색 활용 응용 시스템
부정사용방지 시스템
의료, 사기탐지, 침입탐지

✓ 15. 앙상블 모형에 대한 설명 중 적절하지 않은 것은? * 1/1

- (●) 부스팅(Boosting)은 여러 모델이 순차적 학습을 하며, 붓스트랩 표본을 구성하는 재표본 과정에서 각 자료에 동일한 확률을 부여한다. ✓
- ( ) 랜덤 포레스트는 배깅(Bagging)에 랜덤 과정을 추가한 방법으로 노드 내 데이터를 자식 노드로 나누는 기준을 정할 때 설명변수의 일부분만을 고려함으로 성능을 높이는 방법을 사용한다.
- ( ) 배깅(Bagging)은 원 데이터 집합으로 부터 중복을 허용하는 크기가 같은 표본을 여러 번 단순임의 복원 추출하여 각 표본에 대한 분류기를 생성 후 그 결과를 앙상블 하는 방법이다.
- ( ) 배깅은 반복추출 방법을 사용하기 때문에 같은 데이터가 한 표본에 여러 번 추출될 수도 있고, 어떤 데이터는 추출되지 않을 수도 있다.

의견 보내기

3-83. 앙상블(Ensemble) 모형
부스팅(Boosting)
이전 모델의 결과에 따라 다음 모델 표본 추출에서 분류가 잘못된 데이터에 가중치(weight)를 부여하여 표본을 추출함
맞추기 어려운 문제를 맞추는데 초점이 맞춰져 있고, 이상치(Outlier)에 약함

✓ 16. 다음 중 최근 시계열 데이터에 많은 가중치를 부여하는 분석 방법은? 1/1

- ( ) 자기회귀
- ( ) 이동평균
- (●) 지수평활법 ✓
- ( ) 자기회귀이동평균

의견 보내기

지수평활법
전체 시계열 자료를 이용하여 평균을 구하고, 최근 시계열에 더 큰 가중치를 적용하는 방법
지수 평활을 사용하여 얻은 예측값은 과거 관측값의 가중평균(weighted average)
여기에서 과거 관측값은 오래될 수록 지수적으로 감소하는 가중치를 갖음

✓ 17. 당뇨 환자 25명의 약물 섭취 전, 후 당 수치 변화 평균을 조사하여 치료 효과 등을 분석하는 방법은? *1/1

- ○ 독립표본 t 검정
- ○ 분산분석
- ○ ANOVA
- ◉ 대응표본 t 검정 ✓

의견 보내기

3-61. 모수적 추론 : T-test

대응표본 t-검정
동일 개체에 어떤 처리를 하기 전, 후의 자료를 얻을 때 차이 값에 대한 평균 검정을 위한 방법
가능한 동일한 특성을 갖는 두 개체에 서로 다른 처리를 하여 그 처리의 효과를 비교하는 방법
독립표본 t-test
서로 다른 두 그룹의 평균을 비교하여 두 표본의 차이가 있는지 검정하는 방법

✓ 18. 다음 의사결정나무의 분리기준에 대한 설명 중 적절하지 않은 것은? * 1/1

- ○ 카이제곱 통계량 p값이 가장 작은 예측변수 선택
- ○ 엔트로피 지수가 가장 작은 예측변수 선택
- ◉ 지니 지수를 크게 하는 예측변수 선택 ✓
- ○ 분산의 감소량을 최대화하는 기준 선택

의견 보내기

3-82. 의사결정나무의 결정규칙
분리기준 : 순수도가 높아지는 방향으로 분리(불확실성이 낮아지는 방향)
이산형 목표변수 : 지니지수, 엔트로피 지수, 카이제곱 통계량의 p-value 가장 작은 값을 갖는 방법 선택
연속형 목표변수 : 분산의 감소량을 최대화

✓ 19. 다음 중 주성분분석(PCA)에 결과분석에 설명 중 올바르지 않은 것은? * 1/1

```
> temp <- prcomp(iris[, -5], scale=TRUE)
> summary(temp)
Importance of components:
                          PC1    PC2     PC3     PC4
Standard deviation     1.7084 0.9560 0.38309 0.14393
Proportion of Variance 0.7296 0.2285 0.03669 0.00518
Cumulative Proportion  0.7296 0.9581 0.99482 1.00000
```

- ○ 두 번째 주성분 변수는 전체 데이터의 22.85%를 설명할 수 있다
- ○ 전체데이터의 100%를 설명하기 위해 4개의 주성분이 필요하다
- ◉ 2개의 주성분을 이용해서 전체 데이터의 99% 설명이 가능하다. ✓
- ○ 1개의 주성분만 사용한다면 잃게 되는 정보량이 27.04%이다

의견 보내기

Cumulative Proportion을 보면 2개의 주성분을 이용하면 전체 데이터의 95.81% 설명이 가능하다

✓ 20. 신경망에서 결괏값(출력)을 내보낼 때 사용하는 함수로, 가중치 값을 학습할 때 에러가 적게 나도록 돕는 기능을 하는 것은 무엇인가? *1/1

- ◉ 활성화 함수 ✓
- ○ 로짓함수
- ○ 비용함수
- ○ 임계함수

의견 보내기

3-87. 신경망 활성화 함수
결괏값을 내보낼 때 사용하는 함수로, 가중치 값을 학습할 때 에러가 적게 나도록 도움
풀고자 하는 문제 종류에 따라 활성화 함수의 선택이 달라짐

✓ 21. 오렌지 나무의 dataset에 대한 설명 중 적절하지 않은 것은? * 1/1

```
> summary(Orange)
 Tree       age         circumference
 3:7   Min.   : 118.0   Min.   : 30.0
 1:7   1st Qu.: 484.0   1st Qu.: 65.5
 5:7   Median :1004.0   Median :115.0
 2:7   Mean   : 922.1   Mean   :115.9
 4:7   3rd Qu.:1372.0   3rd Qu.:161.5
       Max.   :1582.0   Max.   :214.0
```

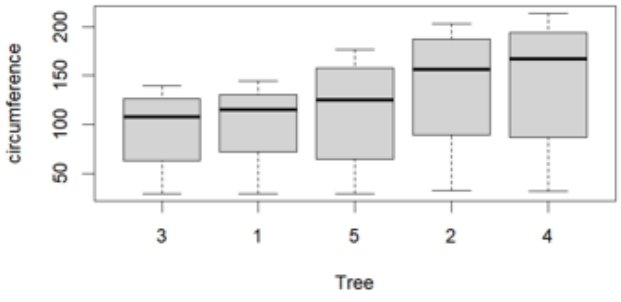

- ○ 결측치가 존재하지 않는다
- ○ age의 최소값은 118.0이다
- ◉ Tree는 연속형 변수이다. ✓
- ○ 3번 Tree의 중앙값이 가장 낮다

의견 보내기

Tree는 1, 2, 3, 4, 5의 값을 갖는 범주형 변수이다
범주별 데이터는 7개씩입니다.

✓ 22. 다음 중 회귀분석에 대한 설명으로 부적절한 것은? * 1/1

- (●) 표본회귀선의 유의성 검정은 회귀선의 기울기의 계수가 β≠0 은 귀무가설, β=0은 대립가설로 설정한다. ✓
- ( ) 일반선형회귀는 종속변수가 연속형 변수일 때 가능하다
- ( ) 회귀분석의 모형 검정은 F-Test, T-Test이다
- ( ) 로지스틱 회귀분석의 모형 탐색 방법은 최대우도법이다.

의견 보내기

귀무가설은 부정하고 싶은 것, 대립가설이 채택하고 싶은 것입니다.
따라서, 표본회귀선의 유의성 검정은 회귀선의 기울기의 계수가 β = 0 은 귀무가설, β ≠ 0은 대립가설로 설정합니다.
기울기 계수(=회귀 계수)는 0 일때 의미가 없는 것입니다.

✓ 23. 아래의 confusion matrix에서 오분류율(Error Rate)을 구하면? * 1/1

		예측치	
		TRUE	FALSE
실제값	TRUE	40	10
	FALSE	20	30

- ( ) 70%
- (●) 30% ✓
- ( ) 20%
- ( ) 25%

의견 보내기

3-91. 오분류표를 활용한 평가 지표
error rate = (FP + FN) / (TP + FP + FN + TN)
전체 예측에서 틀린 예측의 비율

✓ 24. 다음 아래 그림은 주성분 분석의 Scree plot이다. 이 그림을 통해 가정 할 수 있는 주성분 변수의 개수는? *1/1

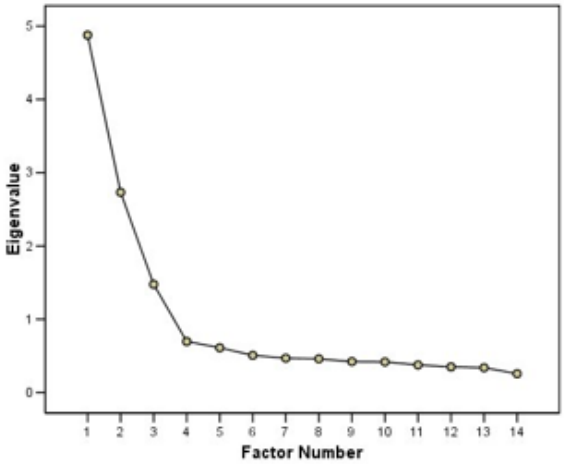

- [ ] 1
- [x] 4 ✓
- [ ] 8
- [ ] 15

의견 보내기

Scree plot에서 각도가 완만하게 꺾이는 곳의 Factor 수를 주성분 변수의 개수로 선택 함 (Eigenvalue를 사용해 해석할 때 1보다 큰 것으로 선택하는 방법도 있음, Kaiser's "eigenvalue>1")
이미지 출처: https://stats.stackexchange.com/questions/513911/scree-plot-m-vs-m-1-components-factors

✓ 25. 아래 표는 주성분 분석의 결과이다. 제 1주성분(PC1) 함수식을 작성하시오. 1/1

```
> fit <-prcomp(USArrests, scale=TRUE)
> summary(fit)
Importance of components:
                          PC1    PC2     PC3     PC4
Standard deviation     1.5749 0.9949 0.59713 0.41645
Proportion of Variance 0.6201 0.2474 0.08914 0.04336
Cumulative Proportion  0.6201 0.8675 0.95664 1.00000
> round(fit$rotation, 3)
             PC1    PC2    PC3    PC4
Murder   -0.536  0.418 -0.341  0.649
Assault  -0.583  0.188 -0.268 -0.743
UrbanPop -0.278 -0.873 -0.378  0.134
Rape     -0.543 -0.167  0.818  0.089
```

PC1 = -0.536*Murder -0.583*Assault -0.278*UrbanPop -0.543*Rape ✓

의견 보내기

대소문자 맞추어서 사용해 주세요 ^_^!

✗ 26. 인공신경망의 활성화 함수에서 목표치가 다범주인 경우 각 범주에 속할 사후 확률을 제공하는 함수는 무엇인가? *…/1

softmax 함수 ✗

정답

소프트맥스 함수

Softmax 함수

Softmax

softmax

의견 보내기

3-87. 신경망 활성화 함수 – softmax 함수
모든 logits의 합이 1이 되도록 output을 정규화
sigmoid 함수의 일반화된 형태로 결과가 다 범주인 경우

✓ 27. 회귀모형의 계수를 추정하는 방법으로 잔차제곱합(SSR)을 최소화 하는 계수를 찾는 방법을 무엇이라고 하는가? *1/1

최소제곱법 ✓

의견 보내기

최소제곱법 - 함수값과 측정값의 차이인 오차(잔차)를 제곱한 합이 최소가 되는 함수를 구하는 방법

✗ 28. 원 자료로부터 붓스트랩 샘플을 추출하고, 각 붓스트랩 샘플에 대해 트리를 형성해 나가는 과정은 배깅과 유사하나, 노드 내 데이터를 자식 노드로 나누는 기준을 정할 때 모든 예측변수에서 최적의 분할을 선택하는 대신, 설명변수의 일부분만을 고려함으로 성능을 높이는 방법을 무엇이라 하는가? *…/1

랜덤 포레스트 ✗

정답

랜덤포레스트

Random Forest

random forest

의견 보내기

3-83. 앙상블 모형 - 랜덤포레스트
배깅(bagging)에 랜덤 과정을 추가한 방법
매번 분할을 수행할 때마다 설명변수의 일부부만을 고려함으로 성능을 높이는 방법

✓ 29. 로지스틱 회귀분석에서 어떤 일이 일어날 확률을 일어나지 않을 확률로 나누어 log를 취하여 값의 범위를 전체 실수 범위로 확장하는 변환 방법을 무엇이라고 하는가? *1/1

로짓 변환 ✓

의견 보내기

3-81. 로지스틱 회귀분석
로짓 변환 : 선형화의 하나, 값의 범위를 전체 실수 범위(-∞~+∞)로 확장
반응변수(=종속변수)의 범위를 -∞ ~ + ∞로 변환할 수 있음

✓ 30. 다음은 모형 기반 군집분석의 결과이다. 아래 그림을 통한 최적의 군집 수는? *1/1

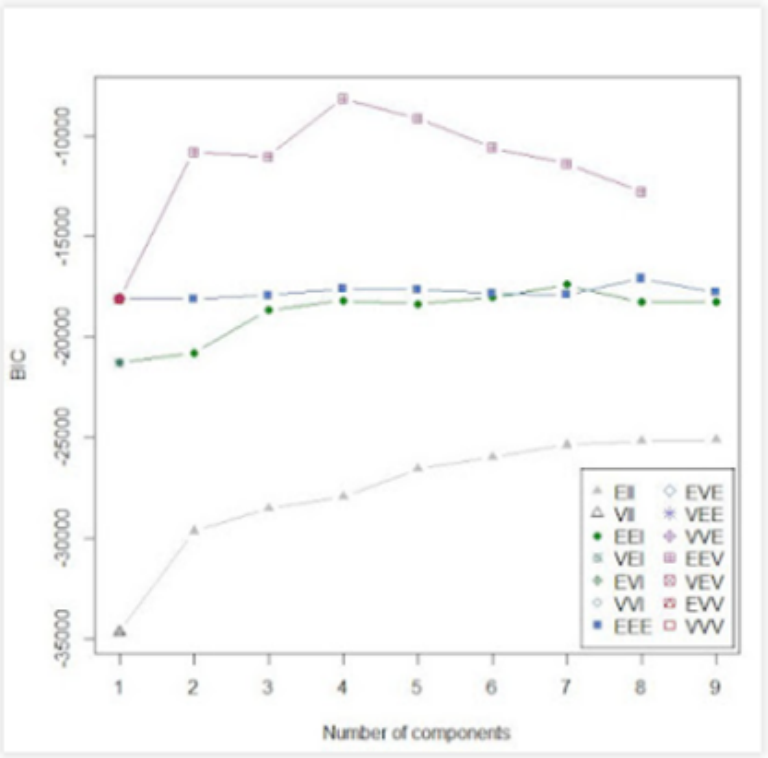

4 ✓

의견 보내기

BIC 그래프 해석 : 모든 plot 에서 가장 큰 값을 갖는 것의 x 값을 최적 군집의 수로 한다